

Vitalia

Especialização do GPT-2 para o Domínio de Saúde e Bem-estar
através de Adaptação de Baixo Rank (LoRA)

AUTORES

Caio Cunha, Franco Alexandre, Franco Rodrigo

DATA

12 de Setembro de 2026

Da base bruta ao assistente confiável

"Especializar um LLM com baixo custo computacional, mantendo rigorosa governança e reprodutibilidade dos dados."

Dispositivo e decisões centralizadas

Detecção de Hardware

Cenário	Device	Dtype	Velocidade
GPU NVIDIA	cuda	FP16	Minutos
Apenas CPU	cpu	FP32	Horas

O uso de **FP16** em GPU reduz a VRAM pela metade e dobra a velocidade sem perda de precisão clínica.

Controle via config.yaml

Parâmetro	Valor	Impacto Prático
epochs	10	Equilíbrio entre aprendizado e custo.
batch_size	4	Cabe em GPUs modestas (4GB+).
learning_rate	1e-4	Estabilidade para adaptadores LoRA.
max_length	256	Evita truncamento de respostas longas.
label_smoothing	0.0	Mantém fidelidade matemática exata.

Uma base útil como rascunho — ainda não como evidência clínica

CARACTERIZAÇÃO DA BASE

Instruções em português com foco em saúde e bem-estar, úteis para prototipagem de fine-tuning e avaliação de LLMs.

O conjunto ajuda a testar comportamento, formato de respostas e adaptação de domínio. Porém, não deve ser tratado como fonte validada para orientação clínica.

Ruídos que limitam o uso sério

ALINHAMENTO

Respostas desalinhadas ou incorretas.

INTEGRIDADE

Truncamentos, repetições e ecos.

LINGUAGEM

Erros de português e mistura de idiomas.

CONFIABILIDADE

Ausência de validação científica.

Antes de usar em produção:

limpar e padronizar os exemplos, checar fatos, remover duplicatas, corrigir truncamentos e revisar o conteúdo com especialistas em saúde.

Preparar o dado antes de tokenizar

PROMPT TEMPLATE (CONFIG.YAML)

Contexto:
{input}

Pergunta:
{instruction}

Resposta:
{output}<eos>

O <eos> final ensina o modelo a encerrar a geração.

1. Formatação

Conversão de pares instrução-resposta para o template estruturado.

2. Split Estratégico

80% Treino / 20% Validação controlado por `validation_split`.

3. Tokenização & Padding

Uso de `max_length=256` com mascaramento de padding (label=-100).

1200

PARES TOTAIS

960

EXEMPLOS TREINO

240

EXEMPLOS VALIDAÇÃO

42

SEED (REPRODUTIBILIDADE)

LoRA: precisão com 0,12% dos parâmetros

Configuração LoRA

Parâmetro	Valor	Impacto Prático
<code>lora_r</code>	4	Evita overfitting em bases pequenas.
<code>lora_alpha</code>	8	Equilibra influência sobre o modelo base.
<code>lora_dropout</code>	0.1	Regularização extra nas matrizes LoRA.
<code>target_modules</code>	<code>c_attn</code>	Foca nas camadas de atenção do GPT-2.

Por que LoRA?

- **Leve:** Adaptador ocupa poucos MB de disco.
- **Rápido:** Treina apenas ~0,12% dos parâmetros.
- **Portável:** O mesmo modelo base recebe vários adaptadores.
- **Eficiente:** Menor risco de esquecimento catastrófico.

147.456

PARÂMETROS TREINÁVEIS

124M

PARÂMETROS TOTAIS

0.118%

PERCENTUAL TREINADO

Análise das curvas e ganho acumulado

PERPLEXIDADE (PPL)

10.85



Melhor valor atingido na Época 10

CONVERGÊNCIA


~94%

Ganho acumulado já na Época 5

Perfil	Época	Val Loss	Perplexidade	Ganho (%)	Justificativa Técnica
Pior	1	2.807	16.6	0%	Underfitting severo — início do aprendizado.
Bom	5	2.412	11.2	~94%	Ponto de equilíbrio — máxima eficiência.
Melhor	10	2.385	10.9	100%	Menor val_loss absoluta, sem overfitting.



Evolução da Taxa de Aprendizado (Cosine Scheduler)



O que quase quebrou o projeto

DADOS & RUÍDO

Traduções híbridas e respostas vazias exigiram limpeza manual exaustiva para evitar alucinações no modelo final.

INFERÊNCIA & ECO

O modelo tendia a repetir a pergunta. Resolvido com ajuste fino do prompt template e penalidade de repetição (2.2).

CONVERGÊNCIA

Instabilidade inicial no treino. O Cosine Scheduler com warmup foi crucial para a estabilização da loss.

Lição Fundamental

"Dados ruins geram modelos ruins. A qualidade da base instrucional é soberana sobre o tamanho do dataset ou a complexidade da arquitetura."

Diferenças: Gemini vs Ótimo

Pergunta	Vitalia	Gemini
O que é hipertensão	A hipertensão pode ser causada por uma série de fatores, incluindo o consumo excessivo de bebidas alcoólicas, a ingestão excessiva de alimentos ricos em gordura e a exposição à radiação ultravioleta.	A hipertensão arterial, popularmente conhecida como "pressão alta", é uma condição crônica caracterizada pela elevação persistente da força que o sangue exerce contra as paredes das artérias ao ser bombeado pelo coração. A pressão arterial é expressa em dois números medidos em milímetros de mercúrio (mmHg): Sistólica (máxima): A pressão nas artérias no momento em que o coração se contrai e bombeia o sangue (ex.: 120 mmHg ou "12"). Diastólica (mínima): A pressão nas artérias quando o coração relaxa entre os batimentos (ex.: 80 mmHg ou "8").